## **Proiect PCLP3**

Duță Ștefan-Horia, 311CA

### Descriere:

### 1. Tipul problemei:

Setul de date este destinat unei probleme de regresie, care consta in predictia veniturilor unei companii.

#### 2. Structura setului de date:

Setul de date va avea 2000 de exemple si este impartit in doua subseturi:

- Subsetul de antrenare: are 1400 de exemple
- Subsetul de testare: are 600 de exemple

#### 3. Caracteristici:

Fiecare instanta are 9 coloane relevante, dintre care "venit" este cea tinta. Pentru acestea am folosit, 3 tipuri diferite de date: numere intregi(numar angajati, an infiintare, numar produse, numar clienti, numar parteneri), numere reale(capital social, venit) si valori categoriale(domeniu de activitate, tara)

#### 4. Salvarea dataseturilor:

Subsetul de antrenare va fi salvat in "train.csv", iar cel de testare in "test.csv".

#### 5. Explicarea modului de constructie a setului de date:

Problema noastra consta in predictia veniturilor unei companii. Setul de date a fost generat aleator, folosind distributia normala si uniforma, cu urmatoarele restrictii: media numarului de angajati este de 100, capitalul social este intre 50000 si 500000 de euro, anul de infiintare este intre 1970 si 2024, numarul de produse este intre 1 si 100, numarul de clienti este intre 50 si 1000, iar numarul de parteneri intre 1 si 20. Tara si domeniul de activitate au fost alese aleator dintr-un set fix de optiuni, acestea fiind Romania, Germania, Franta, Italia, Spania, respectiv, IT, Retail, Agricultura, Educatie, Financiar. Venitul a fost calculat folosind o formula la care contribuie toate caracteristicile unei instante si anume:

(numar\_angajati \* 3000 + capital\_social \* 0.5 + vechime \* 1000 + numar\_clienti \* 500 + numar\_parteneri \* 1000) \* coef\_domeniu \* coef\_tara.

Apoi, alegem un numar intre 50 si 100 de valori din fiecare coloana pentru a le sterge.

# 6. Analiza exploratorie a datelor (EDA complex): Analizare valori lipsa:


numar angajati	54
capital social	83
an infiintare	71
numar produse	70
domeniu de activitate	94
tara	86
clienti	58
parteneri	67
venit	0


In cazul coloanelor cu valori numerice, vom inlocui spatiile libere cu media aritmetica de pe acea coloana, iar in cazul celor cu valori categoriale, vom inlocui cu cea mai frecventa eticheta.


## Statistici descriptive:


	numar angajati	capital social	an infiintare	numar produse	clienti	parteneri	venit
count	2000.0000000	2000.0000000	2000.0000000	2000.0000000	2000.0000000	2000.000000	2.0000000e+03
mean	100.405961	270572.452888	1996.191291	50.118653	533.848095	10.188308	1.020487e+06
std	19.442187	126352.652747	15.374407	28.087174	267.425996	5.337319	3.590860e+05
min	35.000000	50005.235640	1970.000000	1.000000	50.000000	1.000000	2.714512e+05
25%	87.000000	163007.283415	1984.000000	27.000000	305.000000	6.000000	7.477798e+05
50%	100.405961	270572.452888	1996.191291	50.118653	533.848095	10.188308	9.756660e+05
75%	113.000000	373262.840762	2009.000000	73.000000	758.000000	15.000000	1.234982e+06
max	177.000000	499800.966463	2023.000000	99.000000	999.000000	19.000000	2.219132e+06


### Analiza distribuitiei variabilelor:


























Analiza corelatiilor:





## Analiza relatiilor cu variabila tinta:





### 7. Antrenarea si evaluarea unui model de baza:





MAE: 65922.13 RMSE: 98376.38 R^2: 0.9205